

AFMamba: Mamba架构下的高光谱与LiDAR 自适应融合分类网络

翁谦^{1,2,3}, 陈耿葳^{1,3}, 潘增滢^{1,3}, 林嘉雯^{1,2,3}, 郑向涛⁴

1. 福州大学 计算机与大数据学院, 福州 350108;
2. 大数据智能教育部工程研究中心, 福州 350108;
3. 福建省网络计算与智能信息处理重点实验室, 福州 350108;
4. 福州大学 物理与信息工程学院, 福州 350108

摘要: 高光谱图像 HSI (Hyperspectral Image) 可以捕获地物成分的光谱特征, 但缺失三维信息, 而激光雷达 LiDAR (Light Detection And Ranging) 可以捕获地物的距离高度信息, 两类数据相互补充可以有效提升地物识别分类的精度。Mamba 模型具有远程特征学习和高效运算的优势, 但在多模态遥感数据融合分类中的研究较少, 存在多源特征信息缺失, 融合不足等问题。基于此, 本文提出了一种基于 Mamba 结构的高光谱和 LiDAR 数据自适应融合协同分类网络。该网络包括一个可堆叠的基于 Mamba 结构的双通道协同注意力模块, 利用参数共享促进了多源特征之间的相互学习, 从而在分类任务中实现更高的分类精度和更好的泛化能力。实验结果表明, 本文所提算法在 Trento, Houston2013 和 MUUFL 数据集上的总体精度分别达到了 99.33%, 91.74% 和 94.94%, 能够更为高效地提取、融合多源特征。

关键词: 遥感图像分类, 协同分类, 自适应融合, Mamba 结构, 参数共享, 高光谱图像, LiDAR, 多模态数据融合

中图分类号: TP751/P231/P2

引用格式: 翁谦, 陈耿葳, 潘增滢, 林嘉雯, 郑向涛. 2026. AFMamba: Mamba架构下的高光谱与LiDAR自适应融合分类网络. 遥感学报, XX(XX): 1-15

Weng Q, Chen G W, Pan Z Y, Lin J W and Zheng X T. 2026. AFMamba: Adaptive fusion network for hyperspectral and LiDAR data collaborative classification based on Mamba. National Remote Sensing Bulletin, XX (XX): 1-15 [DOI:10.11834/jrs.20254539]

1 引言

近年来, 由于卫星技术的进步, 从各种卫星传感器中捕获多源图像成为可能, 高光谱图像 HSI (HyperSpectral Image) (Wang 等, 2023) 和激光雷达 LiDAR (Light Detection And Ranging) (Hang 等, 2020) 的信息融合应用已受到研究者的广泛关注。HSI 获得地物的光谱曲线, 可以通过不同地面物体的光谱差异来区分它们, 因此, 广泛应用于环境监测、国防、精准农业、矿产勘探等 (Gerard 等, 2010; Zhou 等, 2011; Stuart 等, 2019; Shimoni

等, 2019; Peyghambari 和 Zhang, 2021) 领域。但 HSI 缺乏高度信息, 导致无法区分光谱相近但高度不同的地物。

激光雷达 (LiDAR) 可以获得地形高度信息, 构建数字表面模型数据 DSM (Digital Surface Model), 为 HSI 提供缺失的高度立体和几何信息。LiDAR 数据和高光谱数据作为不同的异质遥感数据, 充分利用两者互补的光谱、空间细节等信息, 可以有效弥补单一模态数据信息量不足的短板, 有助于显著改善分类结果。

为了充分利用 HSI 和 LiDAR 数据信息的互补

收稿日期: 2024-12-07; 预印本: 2025-03-31

基金项目: 福建省自然科学基金面上项目 (编号: 2023J01432); 国家自然科学基金联合基金项目 (编号: U21A20472); 国家重点研发计划 (编号: 2021YFB3600503)

第一作者简介: 翁谦, 研究方向为遥感图像分析、计算机视觉。E-mail: fzuwq@fzu.edu.cn

通信作者简介: 郑向涛, 研究方向为计算机视觉、模式识别。zhengxiangtao@fzu.edu.cn

优势, 人们已经提出了许多的融合分类方法 (Xu 等, 2018; Wan 等, 2021; Song 等, 2023)。在深度学习 (Deep Learning) 发展初期, 卷积神经网络 CNN (Convolutional Neural Networks) 是主流的应用方法。如 Chen 等 (2017) 构建了双分支 CNN 架构, 旨在分别提取 HSI 和 LiDAR 的上下文特征, 进而通过深度神经网络实现深层次的特征融合, 以提升最终的分类性能。Zhang 等 (2020) 则进一步提出了三通道块对块映射方法, 以成功融合 HSI 和 LiDAR 之间的多尺度特征, 进一步提升分类结果。Zhang 等 (2022) 则提出交错感知卷积神经网络, 能够更加高效地异构信息, 从而提高 HSI 和 LiDAR 的联合分类性能。

为了增强模型对复杂问题的解析能力, MLP 在 CNN 框架中的应用愈发广泛。Li 等 (2024) 设计了一种名为 HyperMLP 的网络, 以克服传统网络在空间特征提取和多模态特征融合中的局限性。同时, 注意力机制因其能有效聚焦关键特征区域, 减少信息冗余, 并强化空间特征的提取效果, 也被成功融入 CNN 框架。Mohla 等 (2020) 在此基础上提出交叉注意力机制, 通过将 LiDAR 的空间信息融入 HSI 分支, 大幅增强了 HSI 分支的空间特征表达能力。近来, 基于自注意力 SA (Self Attention) 的深度学习模型——Transformer 由于其强大的长距离依赖关系捕获以及并行处理能力受到了学术界的青睐, Roy 等 (2023) 在 Transformer 的基础上, 引入了一种基于块的多头交叉注意力机制 mCrossPA (Multihead Cross-Patch Attention), 通过对令牌 (token) 的重新规划利用和注意力分配机制, 实现了更高效的信息交互融合。Cheng 等 (2024) 则从网络层间特征融合出发, 提出了跨层自适应注意力融合模块, 实现不同网络层的重要特征信息的融合利用。Xu 等 (2024) 采用双分支方案, 一个 Dynamic-CNN 分支以有效地编码像素的局部特征, 同时一个 Gaussian Transformer 分支以精确建模全局特征和长程依赖关系, 协同工作实现特征的融合和应用, 提高了分类性能。Zhang 等 (2024) 注意到了数据分布中的冗余, 提出了一种基于互信息的信息聚合约束 IAC (Information Aggregation Constraint), 旨在删除冗余信息并保留嵌入特征中的互补信息, 提升计算效率同时提高分类性能。

传统的 Transformer 模型虽然在全局依赖建模

和并行计算方面具有显著优势, 但自注意力机制存在两次计算复杂度的问题。特别是处理高光谱图像 (HSI) 等高维数据时, 计算成本大幅攀升, 限制了实际应用。近年来, 状态空间模型 SSM (State Space Model) 在深度学习领域的发展迅猛 (Rangapuram 等, 2018), 作为可并行处理的时序建模方法备受瞩目。SSM 的计算复杂度和内存占用与序列长度呈线性关系, 这对高效训练和推理意义重大。

近期, 基于 SSM 的新框架——Mamba 模型 (Gu 和 Dao, 2024) 应运而生, 其在计算效率和特征提取能力上表现出色, 在音频和文本任务中超越同规模的 Transformer 模型, 于遥感领域的应用也渐成研究热点。例如, Yao 等 (2024) 提出了 SpectralMamba 模型, 该模型融合了 Mamba-S6 模型 (Gu 等, 2022), 简化了 HSI 数据的动态建模, 避免了冗余的注意力机制和递归操作。Huang 等 (2024) 则利用 Mamba 模块分别提取 HSI 的光谱和空间信息, 有效地利用了 Mamba 高效的计算性能和强大的远程特征提取能力。当下, 已有部分基于 Mamba 模型的 HSI 与 LiDAR 联合分类的工作。例如, Liao 等 (2024) 在 HSI 和 LiDAR 数据之外, 先对 LiDAR 数据采用梯度联合算法得到地物对象的边缘轮廓数据, 再将 3 种模态的数据输入模型, 通过 Mamba 模块捕捉长距离依赖关系, 提升融合算法的性能; Li 和 Huang (2024) 提出全局—局部 Mamba 编码器, 引入了局部变差增加局部对象的空间特征。

然而, 现有基于 Mamba 的融合分类网络未充分考量模态相关性和互补性, 仅用 Mamba 模块对不同的数据特征独立长距离依赖建模, 无法有效提取不同模态的共有语义关系。基于此, 本文提出了一种基于 Mamba 结构的高光谱和 LiDAR 数据自适应融合协同分类网络 AFMamba (Adaptive Fusion Mamba Network)。该方法通过构建双通道 Mamba 编码框架, 分别提取高光谱与 LiDAR 数据的深层语义特征, 并设计协同注意力机制以建模多模态间的长程依赖关系; 同时引入自适应融合策略, 实现两类异构遥感数据的高效互补与联合表征。本研究旨在探索 Mamba 架构在多模态遥感数据融合中的适用性与潜力, 以期为高精度地物分类提供一种新的轻量、高效的多源信息融合范式。

2 AFMamba网络结构

本文提出了一种基于Mamba结构的高光谱和LiDAR数据自适应融合协同分类网络。网络的整体框架如图1所示。首先,利用双分支深度特性提取架构提取HSI和LiDAR数据的空间—光谱联合

特征以及LiDAR的高程语义信息。随后,通过空间上下文标记器进行特征聚合并优化空间表示。处理后的特征序列会被输入到多模态Mamba融合编码器中进行编码并融合,之后通过最终的分层处理后输出对地物的分类结果。




图1 AFMamba网络的整体框架

Fig. 1 Model architecture of AFMamba

2.1 数据预处理

设 HSI 数据为 $X_H \in \mathbb{R}^{M \times N \times B}$, LiDAR 数据为 $X_L \in \mathbb{R}^{M \times N}$, 其中 M 和 N 分别表示图像的宽度和高度, B 表示 HSI 的光谱波段数。地物的真实标签 $y \in \{1, 2, \dots, K\}$, 其中 K 为真实标签的种类数。图像 X_H 中第 i 行第 j 列的像素可以表示为 $x_{i,j} = [x_{i,j,1}, \dots, x_{i,j,B}] \in \mathbb{R}^B$, 其中, $i = 1, 2, \dots, M$, $j = 1, 2, \dots, N$ 。本文方法使用空谱联合的策略, 以空间块作为模型的输入, 在预处理阶段, 先对 HSI 数据 X_H 进行最大最小归一化操作, 之后从中提取以像素 (i, j) 为中心, 相邻区域大小为 $(P \times P)$ 的立方体 $x_{i,j}^{i,j} \in \mathbb{R}^{P \times P \times B}$, 并行地从 LiDAR 数据 X_L 中提取相应的以像素 (i, j) 为中心的空间图像 $x_{i,j}^{i,j} \in \mathbb{R}^{P \times P}$, 其中相邻区域的大小为 $(P \times P)$ 。

2.2 特征提取阶段

HSI 图像的每个像素点都包含多个光谱波段, 本文设计了双分支深度特性提取架构 (F_H, F_L) 作为 HSI-LiDAR 立方体特征提取的主干网络, F_H 被用于提取 HSI 立方体的空间—光谱联合特征, F_L

用于提取 LiDAR 图像的空间高程特征。两者的网络架构如图2所示。




图2 双分支深度特性提取架构

Fig. 2 The architecture of dual-branch deep feature extraction

2.2.1 HSI联合特征提取模块 F_H

为从原始 HSI 中提取具有高度区分性的特征并

去除光谱维中冗余的信息, 本文在模块 F_H 中使用了顺序排列的 Conv3D 和 Conv2D 层。首先, 将大小为 $(P \times P \times B)$ 的 HSI 立方体 $x_h^{i,j}$ 重塑为 $(1 \times P \times P \times B)$, 并通过一个核大小为 $(3 \times 3 \times 9)$ 的 Conv3D 层进行处理, 生成特征表示 $X_{in,1} = \text{Conv3D}(x_h^{i,j})$, 为了保持图像的空间高度和宽度不变, 该层采用的填充为 $(1 \times 1 \times 0)$ 。

接着, 在 Conv2D 层中, 本文引入了 HetConv (Singh 等, 2019) 结构。具体而言, 采用两个并行的 Conv2D 层, 其中一个执行组卷积 (核大小为 3, 组数为 8, 填充为 1), 另一个执行逐点卷积 (核大小为 1, 组数为 1, 填充为 0)。这两个卷积层的输出通过逐元素相加 ($\oplus$), 得到特征表示 $X_{in,2}$, 这个特征提取过程定义如下:

$$X_{in,2} = \text{Conv2D}_{\text{Group}}(X_{in,1}) \oplus \text{Conv2D}_{\text{Pointwise}}(X_{in,1}) \quad (1)$$

最后, $X_{in,2}$ 被输入到一个核大小为 3 的 Conv2D 层中, 生成 HSI 的空间—光谱联合特征序列 $X_{out,H} = \text{Conv2D}(X_{in,2})$ 。在每个 CNN 层后, 都接有各自的批归一化 BN (Batch Normalize) 层以及激活层, F_H 中的前一个激活层使用 ReLU (Rectified Linear Unit) 函数进行激活, 最后的激活层则使用 GELU (Gaussian Error Linear Unit) 函数。BN 层有助于缓解过拟合, 并加速模型的训练过程。ReLU 函数通过引入非线性和避免梯度消失问题, 加速神经网络训练并提升模型性能。GELU 则结合输入值的概率分布, 提供更平滑的非线性激活, 进一步优化模型的表现和稳定性。

2.2.2 LiDAR 空间特征提取模块 F_L

模块 F_L 使用两个连续的 Conv2D 层对大小为 $(P \times P)$ 的 LiDAR 图像 $x_l^{i,j}$ 进行特征提取, 这两个 CNN 的核大小都为 3, 填充为 $(1 \times 1 \times 0)$, 以生成 LiDAR 的高程特征序列 $X_{out,L} = \text{Conv2D}(x_l^{i,j})$, 并使用 GELU 函数进行激活。

2.2.3 空间上下文标记化器 SCT

标记化操作可以将数据分解为可处理的单元, 以便于模型更有效地进行分析和学习。在特征提取之后, SCT 模块首先将大小为 $(11 \times 11 \times 32)$ 的 HSI 和 LiDAR 立方体展平为 (121×32) 的特征块, 然后通过平均池化进行下采样, 在降噪的同时,

对局部信息进行平滑处理。之后将可学习的绝对位置编码嵌入到特征块中, 这使得模型能够捕捉输入数据中各个元素的位置信息, 从而更好地理解数据的顺序或空间关系。该过程可通过以下等式进行概括:

$$\begin{cases} X_{\text{patch}}^H = \text{AP}(\text{Flatten}(X_{\text{out},H})) \oplus \text{PE} \\ X_{\text{patch}}^L = \text{AP}(\text{Flatten}(X_{\text{out},L})) \oplus \text{PE} \end{cases} \quad (2)$$

式中, PE 是可学习的绝对位置编码, Flatten($\cdot$) 代表展平操作, AP($\cdot$) 代表池化层。

2.3 多模态 Mamba 编码器

将特征提取阶段获得的特征序列输入到多模态 Mamba 编码器中进行编码融合, 该编码器由基于 Mamba 结构的双通道协同注意力模块 DCCAM 和自适应特征融合模块 AF 组成。DCCAM 模块通过改建的双分支 Mamba 结构捕获提取到的 HSI 和 LiDAR 特征间的长距离依赖关系, 并通过参数共享确保双模态特征的相关性与互补性, 充分挖掘 HSI 与 LiDAR 特征间的互补信息。为了获得更为稳健的特征, 设计了 AF 模块, 通过权重学习自适应地融合多模态特征。该编码器的具体架构如图 3 所示。

2.3.1 基于 Mamba 结构的双通道协同注意力模块

Mamba 作为一种选择性结构化状态空间模型, 可以基于选择状态空间对长依赖关系进行快速推理建模。本文在 Mamba 的基础上提出了 DCCAM, 进一步优化了 Mamba 结构, 通过双通道输入实现对 HSI 和 LiDAR 特征序列的同步处理。在此基础上, DCCAM 引入了参数共享机制, 通过卷积层将双模态特征映射到同一特征空间, 确保不同模态在数据处理中的一致性。同时, 门控机制的引入保留了各模态的独特特征, 进一步增强了模态间的协同作用。具体如下, 首先对输入特征 X_{patch}^i 进行层归一化操作, 再利用线性层进行处理, 之后将特征切分, 得到主干特征 X_{Bone}^i , 以及用于门控 MLP 的辅助特征 X_{Aux}^i 。

$$X_{\text{Bone}}^i, X_{\text{Aux}}^i = \text{Chunk}\left(\text{Linear}\left(\text{LN}\left(X_{\text{patch}}^i\right)\right)\right) \quad (3)$$

式中, $i \sim (1, 2)$, 表示模态类型, Chunk($\cdot$) 表示分块操作, Linear($\cdot$) 表示线性投影, LN($\cdot$) 表示层归一化。




图3 多模态 Mamba 编码器具体架构

Fig. 3 The framework of Modality Mamba Encoder

之后，利用 SSM 模块对主干特征进行 I/O (Input and Output) 关系建模，而辅助特征通过一个参数共享的 CNN 层进行处理， $\text{Share} = \text{Conv2D}(\cdot)$ 。并选择 SiLU (Sigmoid Linear Unit) 函数进行激活，最后与主干特征进行逐元素相乘，得到加权的主干特征 X_{Att}^i 。具体过程如下：

$$\begin{cases} X_{\text{Bone}}^i = \text{LN}(\text{SSM}(X_{\text{Bone}}^i)) \\ X_{\text{Aux}}^i = \text{SiLU}(\text{Share}(X_{\text{Aux}}^i)) \\ X_{\text{Att}}^i = (X_{\text{Bone}}^i \otimes X_{\text{Aux}}^i) \oplus \text{LN}(X_{\text{Patch}}^i) \end{cases} \quad (4)$$

式中， $\text{Share}(\cdot)$ 代表参数共享层， $\otimes$ 表示逐元素相乘。

2.3.2 自适应融合模块

为了更好地挖掘不同模态信息的互补特征，本文引入了 AF 模块，通过训练过程中自主学习可训练的权重参数来优化特征融合。具体地说，AF 模块会初始化一个与特征序列长度相等的随机向量 v ，通过 sigmoid 函数进行缩放，并利用 softmax 归一化得到权重 $V \sim \mathcal{N}(0, 1)$ ，然后对 DCCAM 模块输出的 X_{Att}^H 和 X_{Att}^L 分别进行加权，加权过的特征通过相加完成特征融合，该过程可以表示为

$$\begin{cases} V = \text{softmax}(\text{sigmoid}(v)) \\ X_{\text{fused}} = (V \otimes X_{\text{Att}}^H) \oplus ((1 - V) \otimes X_{\text{Att}}^L) \end{cases} \quad (5)$$

最后，该融合特征被馈送到分类头中以获得

最终的分类结果。

3 实验结果与分析

为了验证 AFMamba 的有效性和性能，本文选择在 Trento、Houston2013 和 MUUFL3 个广泛应用的 HSI-LiDAR 数据集进行实验验证。

3.1 数据集介绍

3.1.1 Trento 数据集

该数据集采集于意大利特伦托南部的农村地区。激光雷达数据由 Optech Altm 3100EA 传感器获取，高光谱数据则由 AISA Eagle 传感器采集，空间分辨率为 1 m。高光谱数据包含 63 个波段，覆盖范围为 0.42—0.99 μm 。两个数据的尺寸均为 166×600 像素。该数据集包括 6 类地物，共有 819 个训练样本和 29395 个测试样本，如表 1 所示。图 4 (a) 和 (b) 分别展示了 Trento 数据集的伪彩色图像和灰度图。

3.1.2 Houston2013 数据集

该数据集由美国国家科学基金会资助，通过休斯敦大学校园的机载激光测绘中心 (NCALM) 获取 (Debes 等, 2014)。数据集包含 HSI 和 LiDAR 数据，两者的空间分辨率均为 2.5 m，像素大小为 1905×349。HSI 数据由 380—1050 nm，144 个光谱

波段组成。该数据集包括 15 类地物，包含 2832 个训练样本和 12197 个测试样本，如表 2 所示。图 4（c）和图 4（d）分别展示了 Houston2013 数据集的伪彩色图像和灰度图。

表 1 Trento 数据集训练与测试样本分布
Table 1 Number of training and test samples in each class of the Trento dataset

地物编号	类名	训练样本量/个	测试次数/次
1	苹果树	129	3905
2	建筑物	125	2778
3	地面	105	374
4	树林	154	8969
5	葡萄园	184	10317
6	道路	122	3052
总计		819	29395

表 2 Houston2013 数据集训练与测试样本分布
Table2 Number of training and test samples in each class of the Houston2013 dataset

地物编号	类名	训练样本量/个	测试次数/次
1	健康草坪	198	1053
2	受损草坪	190	1064
3	合成草坪	192	505
4	树木	188	1056
5	土壤	186	1056
6	水	182	143
7	住宅区	196	1072
8	商业区	191	1036
9	道路	193	1059
10	高速公路	191	1036
11	铁路	181	1054
12	停车场 1	192	1041
13	停车场 2	184	285
14	网球场	181	247
15	跑道	187	473
总计		2832	12197

3.1.3 MUUFL 数据集

该数据集的场景于 2010 年 11 月在南密西西比大学校园内，使用反射光学系统成像光谱仪（ROSIS）传感器采集（Gader 等，2013）。HSI 数据大小为 325×220 像元，空间分辨率为 1 m。LiDAR 数据提供了两个栅格的高程信息。由于噪声干扰，初始和末端的 8 个波段被移除，最终得到 64 个有效波段。该数据集包括 11 个地物类别，表 3 为从每个类别中随机选择 5% 作为训练样本的分布情

况。图 4（e）和图 4（f）分别展示了 MUUFL 数据集的 RGB 图像和灰度图。




图 4 数据集可视化

Fig. 4 Dataset visualization

表 3 MUUFL 数据集训练与测试样本分布
Table3 Number of training and test samples in each class of the MUUFL dataset

地物编号	类名	训练样本量/个	测试次数/次
1	树木	1171	22075
2	大片草地	213	4057
3	混合表面	339	6552
4	泥土和沙子	97	1729
5	道路	343	6344
6	水	26	440
7	建筑阴影	115	2118
8	建筑物	297	5943
9	人行道	71	1314
10	黄色路缘带	9	174
11	布制面板	12	257
总计		2684	51003

3.2 实验平台及参数

本文实验均基于 PyTorch 框架, 在 NVIDIA A40 GPU 上实现, 使用 Adam 优化器, 训练批量和测试批量分别设为 64 和 500, 初始学习率为 $1\text{E}-4$, 权重衰减为 $5\text{E}-3$, 模型训练 100 个 epoch。所选图像块尺寸为 11×11 , 特征嵌入维数为 32。模型还使用了步长为 50 和 γ 为 0.9 的步长调度器。每个实验重复 3 次, 得到平均值和标准差。

3.3 分类效果及对比试验分析

为了评估本文方法的性能, 本文与多种最先进的多模态分类方法进行了全面的比较与研究, 包括基于 Transformer 的 MFT, MIViT (Yang 等, 2024), 基于图注意力的 GAMF (Cai 等, 2024), 基于对抗学习的 CALC (Lu 等, 2023), 以及基于 Mamba 的 HLMamba。此外, 为了验证 LiDAR 数据的有效性, 本文还与基于 HSI 单模态的 Mamba 网络进行了对比试验, 包括 Spectral-Spatial Mamba 和 SpectralMamba。

本文使用总体准确率 (OA)、平均准确率 (AA)、Kappa 系数以及每类准确率等指标对协同分类性能进行了定量评估。OA 的计算方法是将正确预测的样本数除以样本总数, 而 AA 则是对各类的准确度取平均值。Kappa 系数可作为分类一致性的评估指标。

表 4—6 分别为本文提出的 AFMamba 和其他方法在 Trento、Houston2013 和 MUUFL 3 个数据集上

的详细分类结果, 加粗为最优值, 下划线为次优值。可以看到, AFMamba 在所有数据集上的 OA, AA 和 Kappa 系数均表现出最佳性能, OA 指标分别为 99.33%, 91.74% 和 94.94%, 且在大多数类别上均取得了最高的分类精度。图 5—7 分别展示了 Trento、Houston2013 和 MUUFL 3 个数据集的分类结果可视化图及其对应的真值图像。由于原始数据存在标签稀疏性, 真值图像中包含大量未标注像素, 为更清晰地展示本模型的效果, 本文对背景进行了屏蔽 (背景值设置为 -1) 并填充为黑色, 同时用红框标出主要的误分类区域。

从表 4 的 Trento 数据集上的分类结果中可以看出, 单模态的 Mamba 模型在地面和道路这两种类别的识别上表现不佳, 而 AFMamba 通过结合 LiDAR 数据有效地克服了这一问题, 且在其中的 4 种类别上都取得了最佳性能, 特别是在大面积连续区域的类别 4 (树林) 和类别 5 (葡萄园) 上实现了 100% 的分类精度。对于空间分布相对离散的地面和建筑物类别, 模型仍存在一定程度的误分类, 但整体仍达到了次佳水平。由图 5 的分类结果可见, 大面积同质区域如树林和葡萄园整体识别准确, 边界与真值基本吻合。但在局部细节上仍存在少量误分类。例如, 图 5 (b) 中 A 上图所示, 苹果园边缘的细长地面受噪声干扰, 易被错分; 下图中, 不规则道路因与建筑物光谱相近且空间邻接, 被误判为建筑物。

表 4 不同方法在 Trento 数据集上的分类精度对比

Table 4 Comparison of classification accuracy of different methods on Trento dataset

类编号	SSMamba	SpectralMamba	MFT	MIViT	GAMF	CALC	HLMamba	AFMamba
1	97.96±00.58	96.61±00.01	98.23±00.38	99.19±00.00	96.47±00.56	98.72±00.01	<u>99.56±00.00</u>	99.80±00.00
2	88.37±01.21	81.14±00.01	99.34±00.02	<u>99.35±00.00</u>	98.63±01.30	99.58±00.01	98.88±00.00	98.96±00.00
3	66.31±03.61	58.69±00.00	89.84±09.00	98.53±00.01	96.61±01.12	74.60±00.06	<u>98.40±00.01</u>	97.86±00.00
4	99.26±00.22	83.75±00.00	99.82±00.26	100.00±00.00	<u>99.99±00.01</u>	99.97±00.00	99.97±00.00	100.00±00.00
5	99.61±00.03	88.42±00.02	99.93±00.05	<u>99.96±00.00</u>	99.83±00.07	99.93±00.00	99.78±00.00	100.00±00.00
6	69.02±01.75	68.12±00.03	88.72±00.94	<u>93.46±00.00</u>	91.62±02.32	87.39±00.06	92.27±00.00	95.12±00.00
OA	94.62±00.13	90.54±00.01	98.32±00.25	<u>99.12±00.00</u>	98.43±00.32	98.12±00.00	98.92±00.00	99.33±00.00
AA	86.76±00.76	85.45±00.00	95.98±01.64	98.42±00.00	97.20±00.39	97.48±00.01	<u>98.56±00.00</u>	98.62±00.00
$k \times 100$	92.78±00.17	89.83±00.01	97.75±00.33	<u>98.82±00.00</u>	97.90±00.43	93.36±00.01	98.15±00.00	99.11±00.00

注: 数值加黑和下划线分别表示该类别或指标的最优值和次优值。Kappa 系数 k 已乘以 100 以便于比较。

表 5 展示了 Houston2013 的分类结果, 可以看出, AFMamba 同样取得了最优性能, 在 15 个地物类型中有 6 个类别取得了最优结果, 4 个类别达到了次优结果。尤其在道路、高速路和铁路 3 个类别上, 分类精度有了显著提升。这充分说明了本文

方法能够充分挖掘地物的光谱和高度信息, 实现对相近地物的有效区分。结合表 5 和图 6 可知, 图中左侧的大面积草坪、水体和运动场等区域均得到了准确识别, 而误分类多出现在零散分布的健康草坪、商业区和住宅区类别, 图 6 (b) A 图所

示区域展示了商业区和住宅区错分情况，该区域空间分布较为破碎，且光谱特性相近。进一步观察数据集发现，影像受云雾遮挡，阴影区域和无阴影区域采样数据差异较大，这进一步加剧了误

分类现象。图6（b）B图所示区域为体育场，其中合成草坪与受损草坪交错分布，光谱特性高度接近，容易导致分类混淆。

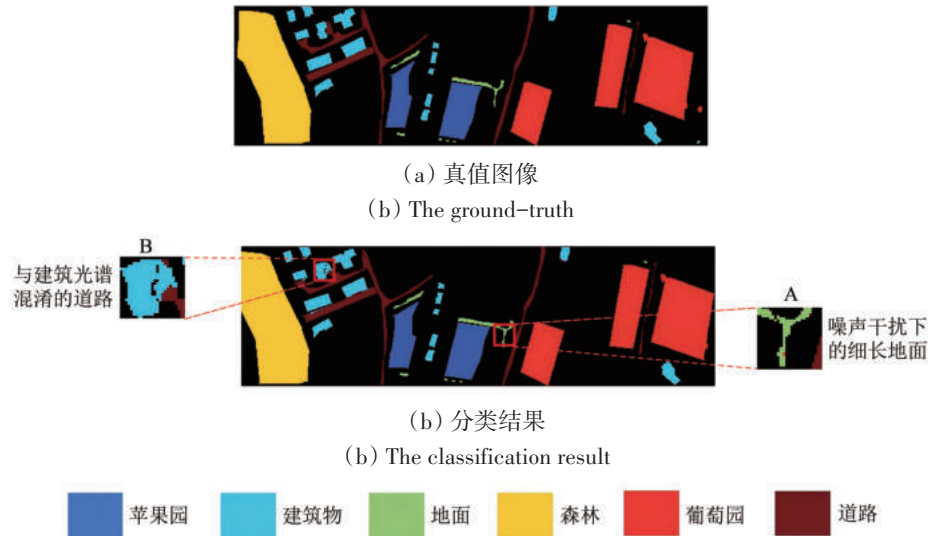


图5 Trento数据集的真值图像和分类结果可视化

Fig. 5 Visualization of the ground truth and classification result of the Trento dataset

表5 不同方法在 Houston2013数据集上的分类精度对比

Table 5 Comparison of classification accuracy of different methods on Houston2013 dataset

类编号	SSMamba	SpectralMamba	MFT	MIViT	GAMF	CALC	HLMamba	AFMamba
1	82.59±00.20	81.82±00.00	82.43±00.54	<u>87.04±00.05</u>	92.34±02.52	81.29±00.01	83.10±00.00	82.78±00.04
2	84.34±00.47	83.51±00.00	84.46±00.04	83.41±00.02	<u>90.38±02.67</u>	84.30±00.00	84.82±00.00	95.99±00.19
3	87.00±02.02	51.98±00.00	98.68±00.49	99.70±00.00	99.56±00.32	92.41±00.03	96.93±00.01	<u>99.60±00.00</u>
4	91.45±00.92	91.81±00.04	95.52±03.03	97.11±00.02	<u>99.18±00.04</u>	91.63±00.03	96.31±00.02	99.83±00.12
5	97.06±00.20	94.08±00.01	99.65±00.16	100.00±00.00	97.43±01.35	<u>99.91±00.00</u>	95.27±00.05	99.81±00.00
6	85.31±01.14	77.28±00.04	<u>95.80±00.00</u>	<u>95.80±00.00</u>	84.76±05.64	97.20±00.01	<u>95.80±00.00</u>	97.20±00.01
7	80.19±02.48	82.19±00.00	83.46±04.50	81.76±00.01	96.59±01.75	85.54±00.02	<u>89.60±00.03</u>	87.38±00.12
8	69.20±04.23	62.11±00.03	79.33±01.31	95.35±00.00	80.12±07.54	<u>85.95±00.04</u>	83.33±00.00	79.80±00.04
9	77.21±01.09	64.73±00.03	88.07±01.96	90.08±00.01	86.01±04.73	83.63±00.04	91.93±00.01	<u>90.31±00.31</u>
10	51.64±03.27	46.72±00.01	54.44±04.07	72.15±00.03	<u>76.97±10.21</u>	67.98±00.00	68.48±00.00	79.05±00.49
11	68.47±03.99	46.64±00.01	96.87±01.42	<u>98.45±00.16</u>	90.82±03.46	97.75±00.02	94.45±00.00	98.53±00.01
12	84.76±05.58	77.67±00.03	88.79±01.53	97.36±00.03	84.87±02.89	94.91±00.02	94.91±00.01	<u>97.08±00.09</u>
13	74.74±02.45	77.37±00.00	83.98±03.87	87.19±00.02	94.29±01.93	87.49±00.03	89.65±00.01	<u>91.22±00.00</u>
14	94.33±01.75	81.38±00.07	100.00±00.00	100.00±00.00	96.39±01.48	<u>99.87±00.00</u>	95.75±00.01	100.00±00.00
15	91.83±01.73	65.33±00.03	99.08±01.01	<u>99.15±00.00</u>	98.59±00.83	98.73±00.02	100.00±00.00	94.64±00.10
OA	79.89±00.16	84.91±00.01	86.82±00.27	<u>91.23±00.00</u>	90.66±00.97	88.34±00.00	89.34±00.00	91.74±00.02
AA	81.34±00.21	79.45±00.00	88.70±00.42	<u>92.40±00.00</u>	91.26±01.84	89.91±00.00	88.46±00.00	92.74±00.02
k×100	78.26±00.17	79.83±00.01	85.69±00.29	90.48±00.00	89.91±02.07	87.37±00.00	<u>90.69±00.00</u>	91.04±00.03

注：数值加黑和下划线分别表示该类别或指标的最优值和次优值。Kappa 系数k已乘以100以便于比较。

表6是 MUUFL数据集的分类结果。AFMamba在OA和Kappa系数上得到了最优值，且取得了第3的AA精度。本方法在11类地物类型中表现出色，其中，5类识别效果最佳，1类次之。尤其是

混合表面、建筑阴影、人行道和布质面板这4类易混淆的地物都得到了较好地识别，这进一步证明了本文方法的优异性能。




图6 Houston2013数据集的真值图像和分类结果可视化

Fig. 6 Visualization of the ground truth and classification result of the Houston2013 dataset

表6 不同方法在 MUUFL 数据集上的分类精度对比

Table 6 Comparison of classification accuracy of different methods on MUUFL dataset

类编号	SSMamba	SpectralMamba	MFT	MIViT	GAMF	CALC	HLMamba	AFMamba
1	96.87±00.16	96.16±00.00	97.61±00.22	97.94±00.00	97.04±01.15	97.96±00.00	<u>98.13±00.00</u>	98.50±00.00
2	79.39±01.79	72.00±00.06	82.78±03.43	89.86±00.00	82.91±04.46	91.43±00.01	<u>90.66±00.00</u>	89.03±00.03
3	82.38±01.18	78.83±00.02	90.85±01.52	87.96±00.02	88.69±02.79	<u>91.10±00.01</u>	90.47±00.01	91.74±00.32
4	95.37±00.91	71.56±00.04	88.72±05.80	95.53±00.01	93.98±01.57	<u>95.01±00.00</u>	93.52±00.00	93.21±00.10
5	95.09±00.39	87.83±00.00	95.89±00.43	95.23±00.00	95.51±00.81	96.58±00.00	<u>96.55±00.00</u>	95.61±00.05
6	94.79±01.22	60.58±00.03	97.01±01.54	100.00±00.00	87.65±10.64	95.29±00.01	<u>99.89±00.00</u>	96.63±00.39
7	85.02±01.98	82.47±00.01	88.12±05.06	<u>94.31 ±00.00</u>	84.12±02.53	91.21±00.01	94.19±00.00	94.47±00.06
8	95.64±00.23	84.69±00.01	96.21±01.41	98.56±00.00	96.84±01.25	<u>98.04±00.01</u>	97.93±00.00	97.75±00.08
9	45.68±02.56	38.77±00.01	33.76±05.63	63.86±00.04	63.77±06.66	47.75±00.01	<u>64.35±00.02</u>	71.22±00.37
10	07.62±00.97	08.86±00.01	00.00±00.00	57.71±00.03	01.91±02.71	00.00±00.00	06.57±00.01	<u>22.05±02.20</u>
11	77.87±00.19	52.60±00.02	75.87±01.97	82.40±00.00	91.70±02.41	81.00±00.08	<u>92.53±00.00</u>	93.60±00.00
OA	91.10±00.13	85.91±00.00	92.37±00.29	94.49±00.00	92.70±00.34	94.26±00.00	<u>94.83±00.00</u>	94.94±00.03
AA	77.91±00.40	66.76±00.01	76.98±01.04	88.60±00.00	80.38±00.43	80.49±00.01	<u>84.37±00.00</u>	83.02±00.04
k×100	88.22±00.17	81.24±00.00	89.88±00.38	92.73±00.00	90.36±00.41	92.40±00.00	<u>93.16±00.00</u>	93.31±00.04

注: 数值加黑和下划线分别表示该类别或指标的最优值和次优值。Kappa 系数 k 已乘以 100 以便于比较。

由图7可见, 大部分地物类别的分类结果较为准确, 但在大片草地、人行道和混合表面等类别中, 仍存在较为显著的混杂误分类现象, 如图7(b)所示。具体而言, 在图7(b) A图, 混合表面与布制面板交错分布, 光谱响应相似, 导致分类困难; 而图7(b) B图中, 草地中的人行道因混合像元和噪声干扰, 极易导致分类混淆。

结合表6和图7, 本文方法在 MUUFL 数据集上

的人行道和布质面板这两类地物上达到了最高的分类精度, 黄色路缘带则表现出次佳性能。

图8—10展示了不同对比方法在3个数据集上的可视化分类效果。可见, 本文方法获得了视觉上更好的结果, 误分率相对较低。因此, AFMamba模型对复杂的细节特征具有较强的捕捉能力, 能够实现更细致且连贯的语义解析, 尤其在处理多样化场景和复杂结构时展现出良好的性能; 同时,

该模型在边界处理上表现出一定的平滑性，能够有效减少识别过程中的不连贯现象。不过，模型

在边缘处理上还有进一步优化的空间，且在少样本情况下的鲁棒性有待提升。




图7 MUUFL数据集的真值图像和分类结果可视化

Fig. 7 Visualization of the ground truth and classification result of the MUUFL dataset




图8 不同方法在Trento数据集上的可视化分类结果

Fig. 8 Visualization results for Trento dataset obtained by different methods

3.4 模块消融实验

为了评估各个模块的重要性，本节将逐步分解 AFMamba 模型，以揭示每个模块的具体效果。消融实验使用双分支深度特性提取架构作为基准网络，采用特征取均值后逐元素相加的方式，并基于 Houston2013 数据集上进行测试。其中，特征聚合后的特征块长度 n 采用最佳性能情况下的设置。

各模块消融结果如表7所示。可见单独使用某

一模块时，AF模块的特征融合对分类性能的提升最为显著。其通过训练过程中自主学习可优化的权重参数，实现了特征融合的精细调节，与基准网络相比，OA 提升了 1.5%，AA 提升了 1.57%，Kappa 系数提升了 1.64%。DCCAM 模块次之，其采用参数共享的方式实现注意力计算，使其能够同时关注不同模态的相关性与互补性，并捕获跨区域的全局依赖关系，有效提升分类精度。SCT 模块则通过池化操作消除数据的冗余特征，因此其单独使用时对性能的提升较低。




图9 不同方法在Houston2013数据集上的可视化分类结果

Fig. 9 Visualization results for Houston2013 dataset obtained by different methods




图10 不同方法在MUUFL数据集上的可视化分类结果

Fig. 10 Visualization results for MUUFL dataset obtained by different methods

在双模块组合进行特征处理时，SCT和DCCAM的协同作用性能表现最佳。这是因为SCT模块减少了冗余特征，DCCAM则进一步强化了全局信息的建模和模态交互，从而达到协同增效的效果。相比之下，AF与SCT模块的结果效果最差，这也说明了全局信息和模态交互的重要性。

当SCT、DCCAM和AF这3个模块共同作用时，模型的精度达到了最高水平。这一实验结果说明本文模型合理组合各模块，在特征提取、全局依赖建模和特征融合优化等多方面进行增强，

从而充分发挥多模态数据的优势，进一步提升分类任务的精度和可靠性。

3.5 保留特征块数量 n 的影响分析

保留的特征块数量 n 是标记化模块中的关键超参数，其取值直接决定模型压缩特征时保留的局部信息总量，同时对模型计算复杂度产生显著影响。较大的 n 有助于保留更多局部细节特征，但可能引入冗余，削弱类别间的判别能力；较小的 n 提升全局抽象能力，却易丢失细粒度地物结构的感知能力。因此，合理选择 n 是实现模型性能与效率

平衡的关键。图 11 展示了保留特征块数量分别为 6、8、10、12 及 14 时模型在 3 个数据集上运行的结果和 3 个评价指标的变化趋势。由图 11 (a) 可见, 在 Trento 数据集上, 分类精度随着的增加整体上呈现出下降的趋势, 在 $n=6$ 时达到最高, 且 3 个评价指标的变化趋势受 n 影响较少。这是由于 Trento 数据集中的地物种类较少, 且具有明显的空间特征和光谱差异, 池化窗口变小 (即 n 变大) 后虽然保留了更多的局部细节, 但可能过于关注某一类地物, 从而忽视其他类别的特征。这种局部细节的过度强调使得模型的分类能力在处理具有复杂空间分布的数据时受到限制, 从而影响了整体的分类性能。由图 11 (b) 和图 11 (c) 可见, 在 Houston2013 和 MUUFL 数据集上, n 的选择过大或过小都会影响分类效果。这是因为这些数据集中的地物类别相对复杂且丰富, 在这种情况下,


模型需要足够的局部信息来区分类别间的细微差异, 但 n 值过大会导致模型失去对局部特征的敏感性, 过于依赖全局信息, 从而削弱分类效果。

表 7 模块消融实验

Table 7 Ablation experiments of each module

						/%
SCT 模块	DCCAM 模块	AF 模块	OA	AA	Kappa	
×	×	×	89.51	90.60	88.60	
√	×	×	89.92	91.50	89.09	
×	√	×	90.80	92.14	90.03	
×	×	√	91.01	92.17	90.24	
√	√	×	91.57	92.38	90.87	
√	×	√	90.19	91.57	89.38	
×	√	√	91.16	92.37	90.41	
√	√	√	91.74	92.74	91.04	

注: 表中“√”和“×”分别表示加入模块和去除模块。

图 11 保留特征块数量 n 对不同数据集 OA, AA, Kappa 系数的影响Fig. 11 Impact of the Number of Retained Feature Tokens n on OA, AA and Kappa across different datasets

3.6 图像块尺寸分析

本文在选择图像块尺寸 (patch size) 时, 综合参考了现有的融合分类研究文献, 并在当前实验环境中对多种尺寸进行了详细对比实验, 最终选择 11 作为模型输入的图像块尺寸。

对比方法中的 MFT 和 GAMF 方法均采用 11 作为 patch size 值, 为保持一致性, 本文也将 11 作为基准值进行消融实验。本文针对 3 个数据集分别进行了图像块的重新划分, 测试了 7、9、11、13 共 4 种图像块尺寸下的分类性能, 具体的实验结果如图 12 所示。可见, 模型精度随图像块尺寸的增加呈上升趋势, 当图像块尺寸为 11 时达到最佳精度, 随后略有下降。在 Trento 和 MUUFL 数据集上, 图像块尺寸对精度的影响较小, 但在 Houston2013 数据集上总体精度变化显著。综合以上因素, 本文设置 11 作为图像块尺寸。




图 12 图像块尺寸对 3 种不同数据集总体精度的影响

Fig. 12 Effect of patch size on OA of three datasets

3.7 计算复杂度分析

6 种不同多模态分类方法的模型参数量、浮点运算量 (FLOPs)、存储成本和时间的计算复杂度分析结果见表 8。可以看出, MFT 以最少的参数量

和最低的 FLOPs 成为计算开销最小的方法。AFMamba 在保持优异分类性能的同时, 展现出良好的计算效率: 在 Houston2013 数据集上, 其参

数量排名第 4, FLOPs 排名第 3; 而在 Trento 和 MUUFL 两个数据集上, 参数量均位列第 3, FLOPs 则排名第 2, 低于同样采用了 Mamba 模块的 HLMamba。

表 8 6 种不同多模态分类方法在 3 个数据集上的参数量、浮点运算量、训练及测试时间对比

Table 8 Parameters, FLOPs, training and testing time of different models on three datasets

数据集	Metric	MFT	MIViT	GAMF	CALC	HLMamba	AFMamba
Trento	参数量\k	263.53	2347.90	4575.49	830.93	264.34	753.71
	浮点运算量\M	14.50	479.37	1307.65	1914.70	57.52	57.42
	训练时间\s	0.75	1.83	61.16	1.04	0.96	0.84
	测试时间\s	1.57	25.13	428.79	6.87	12.40	1.68
Houston2013	参数量\k	313.07	2653.47	7895.57	903.92	330.68	914.71
	浮点运算量\M	27.09	583.89	2443.05	3061.51	78.43	92.32
	训练时间\s	1.94	5.94	430.32	3.84	3.05	2.11
	测试时间\s	1.88	11.78	432.87	4.39	9.51	2.14
MUUFL	参数量\k	249.39	2338.11	3799.12	834.29	262.13	615.64
	浮点运算量\M	12.83	481.96	1230.56	1943.12	58.07	41.19
	训练时间\s	1.66	6.18	250.79	3.31	2.53	1.74
	测试时间\s	2.64	42.46	774.51	11.21	17.22	2.77

比较每个 epoch 的平均训练时间以及所有测试样本的测试时间, 结果如表 8 所示。可见虽然 AFMamba 的参数量和 FLOPs 高于 MFT, 但其训练时间和测试时间接近, 且综合耗时显著优于其他 4 种方法, 这充分证明了 Mamba 结构在提升计算效率方面的优势。综合考虑分类效果、计算成本和性能评估指标, AFMamba 显然是多模态分类方法中的一个具有竞争力的选择。

4 结 论

为了充分利用 HSI 和 LiDAR 数据的互补信息, 同时兼顾计算效率, 本文提出了一种基于 Mamba 结构的高光谱和 LiDAR 数据自适应融合协同分类网络 AFMamba, 并在 3 个数据集上进行实验验证。主要结论如下: (1) 本文设计了一种双分支深度特性提取架构, 并采用了结合池化层和位置嵌入的空间上下文标记器 SCT, 有效地平滑了局部特征, 使模型更具高效性和鲁棒性。在特征融合阶段, 通过基于 Mamba 结构的双通道协同注意力模块 DCCAM 来捕获全局依赖关系, 同时利用参数共享确保异构特征的一致性, 显著提升了计算效率, 最后通过自适应融合模块有效地整合了多源特征, 增强了信息的联合表示。(2) AFMamba 在分类效果和计算效率上均表现优异。在今后的工作中, 将探索半监督和自监督等分类方法在遥感领域的应用。

参考文献 (References)

- Cai J H, Zhang M, Yang H F, He Y T, Yang Y Q, Shi C H, Zhao X J and Xun Y L. 2024. A novel graph-attention based multimodal fusion network for joint classification of hyperspectral image and LiDAR data. *Expert Systems with Applications*, 249: 123587 [DOI: 10.1016/j.eswa.2024.123587]
- Chen Y S, Li C Y, Ghamisi P, Jia X P and Gu Y F. 2017. Deep fusion of remote sensing data for accurate classification. *IEEE Geoscience and Remote Sensing Letters*, 14(8): 1253-1257 [DOI: 10.1109/LGRS.2017.2704625]
- Cheng S L, Chan R and Du A Y. 2024. CACFTNet: a hybrid Cov-attention and cross-layer fusion transformer network for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 62: 1-17 [DOI: 10.1109/TGRS.2024.3374081]
- Debes C, Merentitis A, Heremans R, Hahn J, Frangiadakis N, van Kasteren T, Liao W Z, Bellens R, Pizurica A, Gautama S, Philips W, Prasad S, Du Q and Pacifici F. 2014. Hyperspectral and LiDAR data fusion: outcome of the 2013 GRSS data fusion contest. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 7(6): 2405-2418 [DOI: 10.1109/JSTARS.2014.2305441]
- Gader P, Zare A, Close R, Aitken J and Tuell G. 2013. MUUFL Gulfport hyperspectral and LiDAR airborne data set[R]. Gainesville, FL, USA: FloridaUniv., Tech. Rep. REP-2013-570
- Gerard F, Petit S, Smith G, Thomson A, Brown N, Manchester S, Wadsworth R, Bugar G, Halada L, Bezák P, Boltiziar M, De Badts E, Halabuk A, Mojses M, Petrovic F, Gregor M, Hazeu G, Múcher C A, Wachowicz M, Huitu H, Tuominen S, Köhler R, Olschofsky K, Ziese H, Kolar J, Sustera J, Luque S, Pino J, Pons X, Roda F,

- Roscher M and Feranec J. 2010. Land cover change in Europe between 1950 and 2000 determined employing aerial photography. *Progress in Physical Geography: Earth and Environment*, 34(2): 183-205 [DOI: 10.1177/0309133309360141]
- Gu A and Dao T. 2024. Mamba: linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv: 2312.00752* [DOI: 10.48550/arXiv.2312.00752]
- Gu A, Goel K, and Ré C. 2022. Efficiently modeling long sequences with structured state spaces. *arXiv preprint arXiv: 2111.00396* [DOI: 10.48550/arXiv.2111.00396]
- Hang R L, Li Z, Ghamisi P, Hong D F, Xia G Y and Liu Q S. 2020. Classification of hyperspectral and LiDAR data using coupled CNNs. *IEEE Transactions on Geoscience and Remote Sensing*, 58(7): 4939-4950 [DOI: 10.1109/TGRS.2020.2969024]
- Huang L B, Chen Y S and He X. 2024. Spectral-spatial mamba for hyperspectral image classification. *Remote Sensing*, 16(13): 2449 [DOI: 10.3390/rs16132449]
- Li J J, Liu Y Z, Song R, Liu W, Li Y S and Du Q. 2024. HyperMLP: superpixel prior and feature aggregated perceptron networks for hyperspectral and lidar hybrid classification. *IEEE Transactions on Geoscience and Remote Sensing*, 62: 5505614 [DOI: 10.1109/TGRS.2024.3355037]
- Li S and Huang S. 2024. AFA – mamba: adaptive feature alignment with global – local mamba for hyperspectral and LiDAR data classification. *Remote Sensing*, 16(21): 4050 [DOI: 10.3390/rs16214050]
- Liao D L, Wang Q S, La T and Huang H F. 2024. Joint classification of hyperspectral and LiDAR data based on mamba. *IEEE Transactions on Geoscience and Remote Sensing*, 62: 5530915 [DOI: 10.1109/TGRS.2024.3459709]
- Lu T, Ding K X, Fu W, Li S T and Guo A J. 2023. Coupled adversarial learning for fusion classification of hyperspectral and LiDAR data. *Information Fusion*, 93: 118-131 [DOI: 10.1016/j.inffus.2022.12.020]
- Mohla S, Pande S, Banerjee B and Chaudhuri S. 2020. FusAtNet: dual attention based SpectroSpatial multimodal fusion network for hyperspectral and LiDAR classification//*Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. Seattle: IEEE: 416-425 [DOI: 10.1109/CVPRW50498.2020.00054]
- Peyghambari S M and Zhang Y. 2021. Hyperspectral remote sensing in lithological mapping, mineral exploration, and environmental geology: an updated review. *Journal of Applied Remote Sensing*, 15(3): 031501 [DOI: 10.1117/1.JRS.15.031501]
- Rangapuram S S, Seeger M, Gasthaus J, Stella L, Wang Y Y and Januschowski T. 2018. Deep state space models for time series forecasting//*Proceedings of the 32nd International Conference on Neural Information Processing Systems*. Montréal: Curran Associates Inc.: 7796-7805
- Roy S K, Deria A, Hong D F, Rasti B, Plaza A and Chanussot J. 2023. Multimodal fusion transformer for remote sensing image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 61: 5515620 [DOI: 10.1109/TGRS.2023.3286826]
- Shimoni M, Haelterman R and Perneel C. 2019. Hyperspectral imaging for military and security applications: combining myriad processing and sensing techniques. *IEEE Geoscience and Remote Sensing Magazine*, 7(2): 101-117 [DOI: 10.1109/MGRS.2019.2902525]
- Singh P, Verma V K, Rai P and Namboodiri V P. 2019. HetConv: heterogeneous kernel-based convolutions for deep CNNs//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE: 4830-4839 [DOI: 10.1109/CVPR.2019.00497]
- Song W W, Dai Y, Gao Z, Fang L Y and Zhang Y J. 2023. Hashing-based deep metric learning for the classification of hyperspectral and LiDAR data. *IEEE Transactions on Geoscience and Remote Sensing*, 61: 5704513 [DOI: 10.1109/TGRS.2023.3321057]
- Stuart M B, McGonigle A J S and Willmott J R. 2019. Hyperspectral imaging in environmental monitoring: a review of recent developments and technological advances in compact field deployable systems. *Sensors*, 19(14): 3071 [DOI: 10.3390/s19143071]
- Wan Y L, Qian Y R, Zhong X W, Liu H and Chen L. 2021. Hyperspectral images classification based on double-branch networks with attention feature fusion. *Journal of Applied Remote Sensing*, 15(3): 036517 [DOI: 10.1117/1.JRS.15.036517]
- Wang L Q, Zhu T C, Kumar N, Li Z W, Wu C L and Zhang P Y. 2023. Attentive-adaptive network for hyperspectral images classification with noisy labels. *IEEE Transactions on Geoscience and Remote Sensing*, 61: 5505514 [DOI: 10.1109/TGRS.2023.3254159]
- Xu F L, Mei S H, Zhang G, Wang N and Du Q. 2024. Bridging CNN and transformer with cross-attention fusion network for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 62: 5522214 [DOI: 10.1109/TGRS.2024.3419266]
- Xu X D, Li W, Ran Q, Du Q, Gao L R and Zhang B. 2018. Multi-source remote sensing data classification based on convolutional neural network. *IEEE Transactions on Geoscience and Remote Sensing*, 56(2): 937-949 [DOI: 10.1109/TGRS.2017.2756851]
- Yang B, Wang X, Xing Y, Cheng C, Jiang W W and Feng Q L. 2024. Modality fusion vision transformer for hyperspectral and LiDAR data collaborative classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 17: 17052-17065 [DOI: 10.1109/JSTARS.2024.3415729]
- Yao J, Hong D F, Li C Y and Chanussot J. 2024. SpectralMamba: efficient mamba for hyperspectral image classification. *arXiv preprint arXiv:2404.08489* [DOI: 10.48550/arXiv.2404.08489]
- Zhang J Q, Lei J, Xie W Y, Yang G, Li D X and Li Y S. 2024. Multimodal informative ViT: information aggregation and distribution for hyperspectral and LiDAR classification. *IEEE Transactions on Circuits and Systems for Video Technology*, 34(8): 7643-7656 [DOI: 10.1109/TCSVT.2024.3375511]
- Zhang M M, Li W, Du Q, Gao L R and Zhang B. 2020. Feature extraction for classification of hyperspectral and LiDAR data using patch-to-patch CNN. *IEEE Transactions on Cybernetics*, 50(1): 100-111 [DOI: 10.1109/TCYB.2018.2864670]

Zhang M M, Li W, Tao R, Li H C and Du Q. 2022. Information fusion for classification of hyperspectral and LiDAR data using IP-CNN. IEEE Transactions on Geoscience and Remote Sensing, 60: 5506812 [DOI: 10.1109/TGRS.2021.3093334]

Zhou W Q, Huang G L and Cadenasso M L. 2011. Does spatial config-

uration matter? Understanding the effects of land cover pattern on land surface temperature in urban landscapes. Landscape and Urban Planning, 102(1): 54-63 [DOI: 10.1016/j.landurbplan.2011.03.009]

AFMamba: Adaptive fusion network for hyperspectral and LiDAR data collaborative classification based on Mamba

WENG Qian^{1,2,3}, CHEN Gengwei^{1,3}, PAN Zengying^{1,3}, LIN Jiawen^{1,2,3}, ZHENG Xiangtao⁴

1. College of Computer and Data Science, Fuzhou University, Fuzhou 350108, China;

2. Engineering Research Center of Big Data Intelligence, Ministry of Education, China;

3. Fujian Key Laboratory of Network Computing and Intelligent Information Processing, Fuzhou University, China;

4. College of Physics and Information Engineering, Fuzhou University, Fuzhou 350108, China

Abstract: HyperSpectral Images (HSIs) capture rich spectral signatures for land cover analysis but lack spatial elevation details, while Light Detection And Ranging (LiDAR) provides precise 3D geometric information. Combining these complementary modalities can significantly enhance classification accuracy. However, existing deep learning frameworks, particularly Transformer-based models, face inefficiencies due to the quadratic complexity of self-attention mechanisms when processing high-dimensional HSI data. This study aims to address these limitations by proposing a novel adaptive fusion network that leverages the linear computational efficiency of the Mamba architecture, enabling efficient and accurate joint classification of HSI and LiDAR data.

We propose AFMamba, an adaptive fusion collaborative classification network based on the Mamba architecture. The network features three key components: A dual-branch feature extraction module independently encodes HSI spectral-spatial features and LiDAR elevation information. A stackable dual-channel collaborative attention module built upon Mamba blocks captures long-range dependencies across modalities while enforcing parameter sharing to enhance feature consistency and mutual learning. An adaptive fusion block (AF) dynamically weighs multimodal features through learnable parameters, optimized via layer normalization.

By integrating Mamba's selective state-space model, the network achieves linear computational complexity, efficiently modeling global dependencies without sacrificing spatial-spectral details. The parallel training architecture further reduces computational bottlenecks.

Extensive experiments on three benchmark datasets—Trento, Houston 2013, and MUUFL—demonstrate AFMamba's superiority. The proposed method achieves state-of-the-art overall accuracies of 99.33%, 91.74%, and 94.94%, respectively, outperforming Transformer-based models (MFT, MIViT) and Mamba variants (HLMamba, SpectralMamba).

AFMamba establishes a new paradigm for efficient and accurate fusion of HSI and LiDAR data by integrating Mamba's linear-time modeling capability with parameter-shared cross-modal attention. The method effectively addresses the computational inefficiency of Transformers while achieving superior classification performance through adaptive feature fusion and global dependency learning. Future work will extend this framework to semisupervised scenarios and explore its applicability to other multimodal remote sensing tasks, such as change detection and target recognition.

Key words: remote sensing image classification, collaborative classification, adaptive fusion, Mamba architecture, parameter sharing, hyperspectral image, LiDAR, multimodal data fusion

Supported by Fujian Provincial Natural Science Foundation Project (No. 2023J01432); National Natural Science Foundation of China (No. U21A20472); National Key Research and Development Plan of China (No. 2021YFB3600503).